# Proposta de Projeto: Detecção de Anomalias em Gastos Públicos (Comprasnet)

**Instituição:** FATEC Jacareí

**Tema:** Governança e Compliance

**Abordagem:** Aprendizado não supervisionado

## 1. Contexto e Problema

O Brasil movimenta centenas de bilhões de reais por ano em compras governamentais. O volume de licitações e contratos torna inviável a auditoria manual de todos os processos, e irregularidades como sobrepreço, fracionamento de despesas e concentração de contratos em poucos fornecedores passam despercebidas. Ao mesmo tempo, empresas que vendem ao governo precisam de ferramentas de compliance para mitigar riscos legais, e a sociedade civil carece de instrumentos acessíveis de controle social.

## 2. Objetivo

**Objetivo geral:** desenvolver uma ferramenta de Auditoria Cidadã e Compliance que sinalize automaticamente licitações e contratos com comportamento atípico, usando modelos de aprendizado não supervisionado.

**Objetivos específicos:**

- Construir um pipeline de limpeza e engenharia de atributos sobre os dados abertos de licitações.
- Treinar e comparar Isolation Forest e Autoencoder para detecção de anomalias.
- Gerar um *score de risco* explicável para cada processo.
- Disponibilizar uma interface de auditoria com filtros, rankings e detalhamento por processo.

## 3. Dados

Dataset do Kaggle *Brazilian Public Tenders / Licitações e Contratos*, compilado a partir do Portal da Transparência, com registros de compras governamentais, valores, órgãos e fornecedores.

**Atributos previstos:** valor estimado e homologado, desvio do valor em relação à mediana do mesmo item/categoria, modalidade da licitação, número de participantes, órgão contratante, fornecedor, participação do fornecedor no total gasto pelo órgão, intervalo entre publicação e contrato.

## 4. Metodologia

1. **Análise exploratória:** distribuições, valores ausentes, outliers óbvios e sazonalidade.
2. **Pré-processamento:** padronização de descrições de itens, tratamento de nulos, codificação de categorias, normalização de valores (log).

3. **Engenharia de atributos:** razão preço/mediana do item, índice de concentração (HHI) por órgão, frequência de contratação por fornecedor.
4. **Modelagem:**
    - *Isolation Forest* como modelo base, rápido e interpretável por contribuição de atributos.
    - *Autoencoder* (rede densa) cujo erro de reconstrução serve como score de anomalia.
5. **Avaliação:** como não há rótulos, serão usadas validação qualitativa (revisão manual de uma amostra dos casos mais anômalos), estabilidade entre execuções, comparação entre os dois modelos e, quando possível, casos públicos de irregularidades conhecidas como verificação.
6. **Explicabilidade:** SHAP ou contribuição por atributo para justificar por que um processo foi sinalizado.

## 5. Aplicação Final

Uma aplicação web com:

- **Painel geral** com indicadores, distribuição de scores e evolução temporal.
- **Lista de processos suspeitos**, ordenada por risco, com filtros por órgão, fornecedor, período e valor.
- **Detalhe do processo**, com o motivo da sinalização e comparação com itens similares.
- **Visão de fornecedores**, com concentração de contratos por órgão.
- **Exportação de relatório** para uso em auditoria e compliance.

**Tecnologias sugeridas:** Python (pandas, scikit-learn, TensorFlow/Keras ou PyTorch, SHAP), API em FastAPI e interface web.

## 6. Público-alvo e Valor

- **Empresas fornecedoras do governo:** verificar riscos e inconsistências antes de participar de certames.
- **Órgãos de controle e auditorias independentes:** priorizar onde investigar.
- **Sociedade civil e jornalistas:** acompanhar gastos públicos.
- **Mercado:** GovTech, consultorias jurídicas e auditoria fiscal.

## 7. Riscos e Limitações

- Anomalia estatística **não é prova de irregularidade**: a ferramenta indica prioridade de análise, não culpa. Isso deve estar explícito na interface.
- Ausência de rótulos dificulta métricas objetivas.
- Qualidade e padronização das descrições de itens variam muito.
- Possíveis falsos positivos em itens raros ou de natureza muito específica.

## 8. Cronograma Sugerido

| Etapa | Duração |
|---|---|
| Coleta, EDA e limpeza | 2 semanas |

| Etapa | Duração |
|---|---|
| Engenharia de atributos | 1 semana |
| Modelagem e comparação | 2 semanas |
| Explicabilidade e validação | 1 semana |
| Interface e integração | 2 semanas |
| Relatório final e apresentação | 1 semana |

## 9. Resultados Esperados

Um modelo funcional de detecção de anomalias, um score de risco explicável e um protótipo de interface de auditoria demonstrando o valor da solução para compliance e controle social.